



电子科技大学

电子科技大学（深圳）高等研究院

模式识别

专业	控制科学与工程
班级	5 班
学生	陈玉熙 202122280534
学生	李育泓 202122280515
教师	凡时财
日期	2021.11.25

目 录

1 最小错误率贝叶斯决策	3
1.1 贝叶斯决策	3
1.2 基于最小错误率的贝叶斯决策.....	3
1.3 正态分布下最小错误率贝叶斯决策.....	4
2 最大似然估计 (MLE)	6
2.1 前提条件	6
2.2 似然函数	6
2.3 基本思想	6
2.4 正态分布	7
3 贝叶斯估计 (BE)	8
3.1 基本思想	8
3.2 正态分布	8
4 实验	10
4.1 直方图	10
4.2 最大似然估计	11
4.3 贝叶斯估计	12
4.4 最小错误率贝叶斯决策	12
5 分工与感想	15
5.1 分工	15
5.2 感想	15

1 最小错误率贝叶斯决策

1.1 贝叶斯决策

设实验 E 的样本空间为 S, A 为 E 的事件, B_1, B_2, \dots, B_n 为 S 的一个划分, 且 $P(A) > 0, P(B_i) > 0, (i=1, 2, \dots, n)$, 则贝叶斯公式为:

$$\begin{aligned} P(B_i | A) &= \frac{P(B_i A)}{P(A)} = \frac{P(A | B_i)P(B_i)}{P(A)} \\ &= \frac{P(A | B_i)P(B_i)}{\sum_{j=1}^n P(A | B_j)P(B_j)} \end{aligned}$$

定义条件概率:

$$\begin{aligned} P(A)P(B_i | A) &= P(B_i)P(A | B_i) \\ p(\vec{x})P(\omega_i | \vec{x}) &= P(\omega_i)p(\vec{x} | \omega_i) \end{aligned}$$

其中:

先验概率 $P(\omega_i)$ 表示类 ω_i 出现的先验概率, 简称类 ω_i 的概率;

后验概率 $P(\omega_i | \vec{x})$ 表示 \vec{x} 出现条件下类 ω_i 出现的概率, 称其为类别的后验概率, 对于模式识别来讲可理解为 \vec{x} 来自类 ω_i 的概率;

类概率密度 $p(\vec{x} | \omega_i)$ 表示在类 ω_i 条件下的概率密度, 简称为类概率密度。

贝叶斯法则即为最大后验概率准则。

对于两类 ω_1, ω_2 问题, 可以根据后验概率做判决:

$$\text{若 } p(\omega_1 | \vec{x}) > p(\omega_2 | \vec{x}) \text{ 则 } \vec{x} \in \omega_1$$

$$\text{若 } p(\omega_1 | \vec{x}) < p(\omega_2 | \vec{x}) \text{ 则 } \vec{x} \in \omega_2$$

后验概率 $P(\omega_i | \vec{x})$ 可由类 ω_i 的先验概率 $P(\omega_i)$ 和条件概率密度 $p(\vec{x} | \omega_i)$ 来表示, 即:

$$p(\omega_i | \vec{x}) = \frac{p(\vec{x} | \omega_i)P(\omega_i)}{p(\vec{x})} = \frac{p(\vec{x} | \omega_i)P(\omega_i)}{\sum_{j=1}^2 p(\vec{x} | \omega_j)P(\omega_j)}$$

1.2 基于最小错误率的贝叶斯决策

定义平均错误率为:

$$P(e) = \int_{-\infty}^{\infty} p(e, x) dx = \int_{-\infty}^{\infty} p(e | x) \cdot p(x) dx$$

则在讨论两类问题下，条件错误概率为：

$$P(e | x) = \begin{cases} P(w_1 | x) & \text{当 } P(w_2 | x) > P(w_1 | x) \text{ 时} \\ P(w_2 | x) & \text{当 } P(w_1 | x) > P(w_2 | x) \text{ 时} \end{cases}$$

判决门限，即两类的分界面 t ，如图 1-1 所示：




图 1-1 两类分界面图

对于大量样本 x ，则总的错误概率是 $P(e | x)$ 的数学期望，总错误率为：

$$\begin{aligned} P(e) &= \int_{-\infty}^{\infty} p(e | x) p(x) dx \\ &= \int_{-\infty}^t P(w_2 | x) p(x) dx + \int_t^{\infty} P(w_1 | x) p(x) dx \\ &= \int_{-\infty}^t p(x | w_2) P(w_2) dx + \int_t^{\infty} p(x | w_1) P(w_1) dx \\ &= P(w_2) \int_{-\infty}^t p(x | w_2) dx + P(w_1) \int_t^{\infty} p(x | w_1) dx \\ &= P(w_2) p_2(e) + P(w_1) \cdot p_1(e) \end{aligned}$$

最小错误率贝叶斯决策规则，即选择 t 使得对于每个 x ， $P(e | x)$ 为最小，则 $P(e)$ 也为最小。

决策规则推广到多类决策：

$$\text{若 } P(w_i | x) = \max_{j=1,2,\dots,c} P(w_j | x) \text{ 则 } x \in w_i$$

1.3 正态分布下最小错误率贝叶斯决策

最小错误率贝叶斯决策的判别函数是：

$$g_i(x) = p(x/w_i)P(w_i)$$

其中 $p(x/w_i)$ 服从 $N(\mu_i, \Sigma_i)$ $i = 1, \dots, c$

$$p(x/w_i) = \frac{1}{(2\pi)^{d/2} |\Sigma_i|^{1/2}} \exp \left[-\frac{1}{2} (x - \mu_i)^T \sum_i^{-1} (x - \mu_i) \right]$$

进行单调的对数变换，则判别函数为：

$$\begin{aligned} g_i(x) &= \ln[p(x/w_i)P(w_i)] \\ &= -\frac{1}{2} (x - \mu_i)^T \sum_i^{-1} (x - \mu_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln \left| \sum_i \right| + \ln P(w_i) \end{aligned}$$

最小错误率贝叶斯决策的决策面方程是：

$$g_i(x) = g_j(x)$$

即

$$g_i(x) - g_j(x) = 0$$

$$\begin{aligned} g_i(x) - g_j(x) &= -\frac{1}{2} \left[(x - \mu_i)^T \sum_i^{-1} (x - \mu_i) - (x - \mu_j)^T \sum_j^{-1} (x - \mu_j) \right] \\ &\quad - \frac{1}{2} \ln \frac{|\Sigma_i|}{|\Sigma_j|} + \ln \frac{P(\omega_i)}{P(\omega_j)} = 0 \end{aligned}$$

2 最大似然估计（MLE）

2.1 前提条件

- （1）待估参数 θ 是确定的非随机的未知量；
- （2）按类别把样本集分为 C 个子集： X_1, X_2, \dots, X_C ，任意一个子集 X_i 的样本是从总体中独立抽取的，即每一个样本集 X_i 中样本都是独立同分布的随机变量；
- （3）每个类条件概密函数 $p(x/w_i)$ 的形式已知，未知的是参数向量 θ_i 的值；
- （4）不同类别的参数 θ_i 是独立的，即 X_i 中的样本不包含 $\theta_j (j \neq i)$ 的信息，只包含 θ_i 的信息（ X_i 与 θ_j 无关）。

2.2 似然函数

设样本子集 $X = \{x_1, x_2, \dots, x_N\}$,

当样本是独立抽取的，则似然函数为：

$$p(X/\theta) = p(x_1, x_2, \dots, x_N | \theta) = \prod_{K=1}^N p(x_K/\theta)$$

当 X 的 N 个样本确定后， $p(X/\theta)$ 只是 θ 的函数，记为 $l(\theta)$ 。

2.3 基本思想

（1）若 θ 已知，当从观测值中抽取样本 x_1, x_2, \dots, x_N 时，最可能出现的样本是使 $l(\theta)$ 为最大的样本。

（2）若 θ 未知， X 选定。不同的 θ 选择，对 N 个样本 x_1, x_2, \dots, x_N 就有不同的 $p(X/\theta)$ 值，应选择使 x_1, x_2, \dots, x_N 的似然函数 $l(\theta)$ 为最大的 $\hat{\theta}$ 。

使 $p(X/\theta)$ 达极大值的参数向量 $\hat{\theta}$ ，就是 θ 的最大似然估计。

显然使 $l(\theta)$ 最大的 $\hat{\theta}$ 是样本 x_1, x_2, \dots, x_N 的函数，记为 $\hat{\theta} = d(x_1, x_2, \dots, x_N)$ 。

2.4 正态分布

(1) Σ 已知, μ 未知

似然函数为:

$$H(\mu) = \ln l(\mu) = \ln p(X/\mu) = \ln \prod_{k=1}^N p(x_k/\mu) = \sum_{k=1}^N \ln p(x_k/\mu)$$

可推导出:

$$\hat{\mu} = \frac{1}{N} \sum_{k=1}^N x_k。$$

(2) μ 、 Σ 均未知 (考虑一维情况 $d=1$)

似然函数为:

$$H(\theta) = \ln l(\theta) = \ln p(X/\theta) = \ln \prod_{k=1}^N p(x_k/\theta) = \sum_{k=1}^N \ln p(x_k/\theta)$$

可推导出:

$$\hat{\mu} = \frac{1}{N} \sum_{k=1}^N x_k, \quad \hat{\sigma}^2 = \hat{\theta}_2 = \frac{1}{N} \sum_{k=1}^N (x_k - \hat{\mu})^2$$

3 贝叶斯估计 (BE)

3.1 基本思想

待估参数 θ 为服从某种先验分布的随机量，其先验概率密度为 $p(\theta)$ ，利用已知的训练样本，使 θ 的初始密度估计 转化为后验概率密度 $p(\theta/X)$ 。

定义估计风险： $\lambda(\hat{\theta}, \theta)$ ，对应 $\lambda(\alpha_i, w_i)$ 。

总平均风险为：

$$\begin{aligned} R &= \int_{E^d} R(\alpha_i/x) p(x) dx = \int_{E^d} \sum_{j=1}^C \lambda(\alpha_i, w_j) P(w_j/x) \cdot p(x) dx \\ &= \int_{E^d} \sum_{j=1}^C \lambda(\alpha_i, w_j) P(x, w_j) dx = \int_{E^d} R(\hat{\theta}/x) p(x) dx \end{aligned}$$

定义风险条件： $R(\hat{\theta}/x) = \int_{\Theta} \lambda(\hat{\theta}, \theta) p(\theta/x) d\theta$ ，可得到：

$$\begin{aligned} R &= \int_{E^d} R(\hat{\theta}/x) p(x) dx = \int_{E^d} \int_{\Theta} \lambda(\hat{\theta}, \theta) p(\theta/x) \cdot p(x) d\theta dx \\ &= \int_{E^d} \int_{\Theta} \lambda(\hat{\theta}, \theta) p(x, \theta) d\theta dx \end{aligned}$$

最终目标是求得的 θ 的估计值 $\hat{\theta}$ 应使 R 最小，即等价于求使条件风险 $R(\hat{\theta}/x)$

最小的估计值 $\hat{\theta}$ 。

3.2 正态分布

假设为一维正态分布，已知 σ^2 ，估计 μ 。

假设概率密度服从正态分布 $p(x/\mu) \sim N(\mu, \sigma^2)$, $p(\mu) \sim N(\mu_0, \sigma_0^2)$ ，已知第 i 类样本集 $X = (x_1, x_2, \dots, x_N)^T$ ，第 i 类联合概率密度 $p(X/\mu, x) = p(X/\mu)$

μ 后验概率为：

$$p(\mu | X) = \frac{p(X | \mu) \cdot p(\mu)}{\int p(X | \mu) p(\mu) d\mu}$$

$p(\mu | X)$ 仍然是一个正态函数， $p(\mu/X) \sim N(\mu_N, \sigma_N^2)$ ，可直接写成正态形式：

$$p(\mu | X) = \frac{1}{\sqrt{2\pi}\sigma_N} \exp\left[-\frac{1}{2}\left(\frac{\mu - \mu_N}{\sigma_N}\right)^2\right]$$

对 μ 的估计为:

$$\hat{\mu} = \mu_N = \frac{\sigma_0^2}{N\sigma_0^2 + \sigma^2} \sum_{k=1}^N x_k + \frac{\sigma^2}{N\sigma_0^2 + \sigma^2} \mu_0$$

若令 $p(\mu) = N(\mu_0, \sigma_0^2) = N(0,1)$, 则有:

$$\hat{\mu}_N = \frac{1}{N+1} \sum_{k=1}^N x_k$$

贝叶斯估计是样本信息与先验信息的加权平均, 反映的是先验知识与样本信息的可靠性度量:

$$\begin{aligned} \hat{\mu} = \mu_N &= \frac{\sigma_0^2}{N\sigma_0^2 + \sigma^2} \sum_{k=1}^N x_k + \frac{\sigma^2}{N\sigma_0^2 + \sigma^2} \mu_0 \\ &= \frac{N\sigma_0^2}{N\sigma_0^2 + \sigma^2} m_N + \frac{\sigma^2}{N\sigma_0^2 + \sigma^2} \mu_0 \end{aligned}$$

4 实验

基于提供的数据进行作业的分析。并假定男生、女生的身高、体重、鞋码、50m 成绩、肺活量都服从正态分布。

- 1.以肺活量为例，画出男女生肺活量的直方图并做对比；
- 2.采用最大似然估计方法，求男女生肺活量的分布参数；
- 3.采用贝叶斯估计方法，求男女生肺活量的分布参数（方差已知，注明自己选定的参数情况）；
- 4.基于身高和体重，采用最小错误率贝叶斯决策，画出类别判定的决策面。并判断某样本的身高体重分别为(165,50)时应该属于男生还是女生？为(175,55)时呢？

原始数据（部分）如图 4-1 所示：

编号	性别 男1女0	籍贯	身高 (cm)	体重 (kg)	鞋码	50米成绩	肺活量	喜欢颜色	喜欢运动	喜欢文学	喜欢数学	喜欢模式识别
1	1	湖北	163	51	41	7.5	2500	蓝	1	1		
2	1	河南	171	64	41	7.5	3500	蓝	0	0		
3	1	云南	182	68	45	7.8	4900	蓝	1	0		
4	1	广西	172	66	42	8.2	4800	绿	0	1		
5	1	四川	185	80	44	8.5	5100	蓝	0	0		
6	0	河北	164	47	38	9	2500	紫	1	1		
7	0	河南	160	46	38	9	2500	白	1	1		
8	1	重庆	170	46	41	7	3000	蓝	1	1		
9	1	重庆	178	60	41	7	4200	绿	0	0		
10	1	江苏	180	71	43	7.5	3500	紫	0	0		

图 4-1 原始数据（部分）图

4.1 直方图

使用 Python 语言编程，调用 xlrd 库的函数来读取 excel 文件中对应工作表中的数据，将男女生的肺活量数据分别存储在两个数组中。

由于原始数据存在缺失值或异常值等异常数据，所以需要先对数据进行清洗。同时由于原始数据中各数据相对独立，不存在关键数据，所以并未考虑采取插补法、建模法等办法来修复数据，而是直接将异常数据删除。最终编程实现判断肺活量的值是否不为 0，以及值的类型是否为 float，若不满足要求则将数据删除。

最后调用 matplotlib.pyplot 库的函数分别画出女生、男生的肺活量直方图，

如图 4-1 所示：




图 4-1 女生、男生肺活量直方图

由图可看出，女生肺活量整体低于男生肺活量，女生肺活量集中在 2000~4000，男生肺活量集中在 3000~5000。同时可以看出，女生、男生肺活量虽然大体上呈现中间人数多，两边人数少，但并未完全服从正态分布，主要原因是因为数据量比较少，特别是女生数据量太少，导致与正态分布模型形式相差较大。

4.2 最大似然估计

我们假设男生女生肺活量分布服从一维正态分布，均值与方差均未知，由第二章分析可得出计算公式，使用 Python 编程可以容易算出参数，具体所求参数如表 4-1 所示：

表 4-1 女生、男生肺活量最大似然估计参数表

	女生肺活量	男生肺活量
均值(μ)	3246.6591	4304.5543
方差(σ)	565218.3383	548884.6471

由表可以看出，女生、男生肺活量的方差都很大，说明数据波动大，也再次说明了由于数据样本少，导致数据的分布较为分散。

4.3 贝叶斯估计

由前述贝叶斯估计的推导，贝叶斯估计是样本信息与先验信息的加权平均：

$$\begin{aligned}\hat{\mu} &= \mu_N = \frac{\sigma_0^2}{N\sigma_0^2 + \sigma^2} \sum_{k=1}^N x_k + \frac{\sigma^2}{N\sigma_0^2 + \sigma^2} \mu_0 \\ &= \frac{N\sigma_0^2}{N\sigma_0^2 + \sigma^2} m_N + \frac{\sigma^2}{N\sigma_0^2 + \sigma^2} \mu_0\end{aligned}$$

由此本题可以对肺活量两种特殊情况下的分布参数进行估计：

（1）当认为样本的先验知识完全可靠，则调和均数的样本信息成分近似为 0。方差已知且为 1 的情况下，贝叶斯估计的 $\hat{\mu}$ 即为先验知识 μ_0 。

（2）当认为样本的先验知识完全不可靠，则调和均数的先验信息成分近似为 0。方差已知且为 1 的情况下，贝叶斯估计的 $\hat{\mu}$ 即为样本知识 μ 。

实验具体结果如表 4-2 所示：

表 4-2 女生、男生肺活量贝叶斯估计参数表

	女生肺活量	男生肺活量
特殊情况 1: (先验知识可靠, 样本不起作用) $\mu_0 = 3240; \sigma_0 = 0; \sigma = 1$	3240	3240
特殊情况 2: (先验知识十分不确定, 完全依靠样本信息) $\mu_0 = 3240; \sigma_0 = 10000; \sigma = 1$	3246.6591	4304.5543

4.4 最小错误率贝叶斯决策

本题的最小错误率贝叶斯决策基于男女生的身高体重数据，我们假设男女生身高体重分别服从正态分布。最终画出最小错误率的贝叶斯决策图如图 4-2 所示：

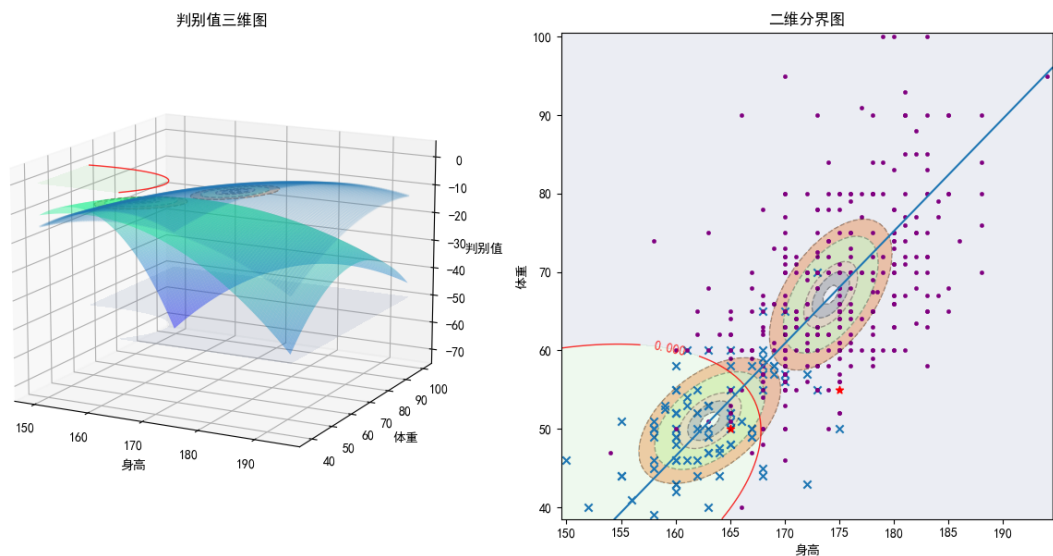


图 4-2 基于最小错误率的贝叶斯决策图

首先由题设，类数 $c = 2$ ，特征数 $d = 2$ ，女生和男生类分别为 w_1 、 w_2 。

由输入数据，计算训练样本的相关参数：

	女生身高	女生体重	男生身高	男生体重
均值(μ)	163.125	51.045	174.204	67.107
协方差矩阵 (Σ)	[23.214 14.356 14.356 35.475]		[34.959 32.611 32.611 102.986]	

然后，我们计算矩阵中各类的后验概率：

$P(\omega_1)$	20.09%
$P(\omega_2)$	79.91%

接着，利用均值矩阵、协方差矩阵和后验概率，由判别函数计算基于样本的 w_1 和 w_2 判别值：

$$g_i(x) = -\frac{1}{2}(x - \mu_i)^T \sum_i^{-1} (x - \mu_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln \left| \sum_i \right| + \ln P(w_i), \quad i = 1, 2$$

根据二维采样点的判别值，我们可以分别绘制出空间内 w_1 和 w_2 判别函数的等密度环以及密度曲面，如图 4-2 所示。

最后，我们计算决策面：

$$g(x) = g_1(x) - g_2(x) = -\frac{1}{2} \left[(x - \mu_1)^T \sum_1^{-1} (x - \mu_2) - (x - \mu_1)^T \sum_2^{-1} (x - \mu_2) \right] - \frac{1}{2} \ln \frac{|\Sigma_1|}{|\Sigma_2|} + \ln \frac{P(\omega_1)}{P(\omega_2)} = 0$$

由决策面方程，我们可以绘制出一条二次曲线，如图 4-2 上红线所示。这条线将二维空间上的决策线，落在小于 0 区域的即属于 w_1 ，反之属于 w_2 。同时也可以从左侧立体图看到，密度曲面的相交投影即为二维空间上分类决策线。

同时，也易知题目中(165,50)和(175,55)两样本（如图 4-2 上红星所示），分别属于女生和男生的区域。由此通过样本的最小错误率贝叶斯决策计算出身高 165，体重 50 的样本属于女生；身高 175，体重 55 的样本属于男生。

5 分工与感想

5.1 分工

陈玉熙：负责实验第 3、4 题编程实现与报告撰写。

李育泓：负责实验第 1、2 题编程实现与报告撰写；负责报告模板格式整理，负责报告前三章理论知识的梳理与撰写。

5.2 感想

陈玉熙、李育泓：这一次的作业是关于两种参数估计方法——最大似然法跟贝叶斯估计，以及贝叶斯决策的内容，在假定正态分布的情况下，对提供的数据进行分析与处理。在对理论知识的梳理之中，我加深了对知识的理解，而在编程实现中，又加深了对公式的印象。

在拿到数据后，首先自然要对数据进行分析，在读取之后取出有效的部分，画直方图其实也是对数据进行分析，可以直观地感受到数据的实际分布，对数据有一个更清晰的把握。之后对数据的参数进行估计，最大似然估计把待估参数看作确定的量，最佳估计即概率最大，在假定正态分布下，其均值就是算术平均值；而贝叶斯估计认为参数服从某种分布，在假定正态分布下，其均值其实是样本信息跟先验信息的加权平均，需要权衡两者的可靠性，在选择不同参数的情况下会有不同的结果，同时存在两种极端情况。而最后的基于最小错误率的贝叶斯决策，其实就是要求最大后验概率，先验概率是男女生比例可以容易求得，而类概率密度我们假定其满足正态分布，跟课程例子有区别，题目是二维的数据，通过跟队友讨论，类比一维正态分布的交点 t ，我们假定二维数据满足二维正态分布，那其类概率密度图像应该是类似于小山坡，男女生对应的两个图会有一个交平面，这个面就是决策面了。

在小组合作中，既要清晰分工，完成自己的负责的内容，但也要参与进其他的部分，不管哪一题是谁实现的，最终都是要一起掌握方法与技巧。同时还要积

极沟通，一个人可能会想得不够全面，或者有所缺漏，而沟通就是一个很好的机会去互相学习，去接触不同的思路，去学习不同的方法，才能得到更大的收获。